Demo

Vídeo de la demo (Google Drive)

Ver el vídeo

Tarvia · analista N1 con IA

- **IA** investiga
- **Política** decide la severidad
- **Persona** aprueba la contención

4.000 alertas al día · unos 15 min cada una a mano · de noche nadie mira la consola

Lluis Sarries · Adrián Valverde · Marc Cantero · Izan Caballer

Así tría una alerta

Cambio de IBAN a Lituania
Fraude BEC tras AiTM

0,2 ms acumulado

1 **Entrada** 2 · 0,2 ms
2 **Contexto** 9 · 1,6 ms
3 **Inteligencia** 1 · 0,0 ms
4 **Política** 1 · 45 ms
5 **IA + revisor** 2 · 69,8 s
6 **Correlación** 1 · 0,5 ms
7 **Persona** humano

● **Código** recoge datos ● **Política** decide por reglas ● **IA** razona y propone ● **Persona** aprueba

Entrada

● **Código**

Lee la alerta (API o cualquier JSON) y extrae sus entidades.

UC-EML-004 ■ medium EMAIL_GW · 2026-10-08 08:19 UTC

Petición de cambio de datos bancarios por correo

usuario laura.ferrer2@tarvia.example | usuario jordi.serra2@tarvia.example | IP 203.0.113.45

La severidad de la regla no es la final: la decide la política.

Así tría una alerta

Cambio de IBAN a Lituania
Fraude BEC tras AiTM

1,8 ms acumulado

1 **Entrada** 2 · 0,2 ms
2 **Contexto** 9 · 1,6 ms
3 **Inteligencia** 1 · 0,0 ms
4 **Política** 1 · 45 ms
5 **IA + revisor** 2 · 69,8 s
6 **Correlación** 1 · 0,5 ms
7 **Persona** humano

● **Código** recoge datos ● **Política** decide por reglas ● **IA** razona y propone ● **Persona** aprueba

Contexto

● **Código**

Lo que un analista miraría a mano: activo, usuario, logs ±24 h, otras alertas y cambios aprobados.

Directorio
2 consultas
DPO (Legal y Cumplimiento) · 1 eventos RRHH
QA Engineer (E-commerce)

Logs
5 consultas
1 encontrados
44 eventos en edr_events, email, idp_signins, proxy

SIEM
1 consulta
6 alertas relacionadas

Cambios
1 consulta
3 cambios: CHG-2026-1042, CHG-2026-1031, FLUJO-0007

Así tría una alerta

Cambio de IBAN a Lituania
Fraude BEC tras AiTM

1,8 ms acumulado

1 **Entrada** 2 · 0,2 ms
2 **Contexto** 9 · 1,6 ms
3 **Inteligencia** 1 · 0,0 ms
4 **Política** 1 · 45 ms
5 **IA + revisor** 2 · 69,8 s
6 **Correlación** 1 · 0,5 ms
7 **Persona** humano

● **Código** recoge datos ● **Política** decide por reglas ● **IA** razona y propone ● **Persona** aprueba

Inteligencia

● **Código**

TIP, GeoIP, sandbox y OSINT para cada indicador. Solo reputación: nunca se visita nada.

Dato	203.0.113.45	GeoIP: NL Hosting Ámsterdam BV (simulado) [is_hosting]

Así tría una alerta

Cambio de IBAN a Lituania
Fraude BEC tras AiTM

46 ms acumulado



Código recoge datos · **Política** decide por reglas · **IA** razona y propone · **Persona** aprueba

Política

Política

Severidad = regla × criticidad del activo. Si la explicación es inequívoca, cierra sin IA.

regla **medium** × activo jordi.serra2@tarvia.example **Media** = política **high**

`USER_VACACIONES` `ANON_INFRA` `TI_UNKNOWN` `PERSONAL_DATA_OR_PAYMENTS`

No es concluyente: lo decide la IA.

Así tría una alerta

Cambio de IBAN a Lituania
Fraude BEC tras AiTM

69,9 s acumulado



Código recoge datos · **Política** decide por reglas · **IA** razona y propone · **Persona** aprueba

IA + revisor

IA

Claude, sin herramientas, decide con evidencias citadas. Un revisor crítico lo comprueba.

Verdadero positivo

confianza 88 %

high la IA mantiene la severidad de la política

`EML-0062205` `SIGN-0012259` `alert` `alert`

Revisor crítico de acuerdo: 4 evidencias comprobadas, 0 eliminadas.

Así tría una alerta

Cambio de IBAN a Lituania
Fraude BEC tras AiTM

69,9 s acumulado

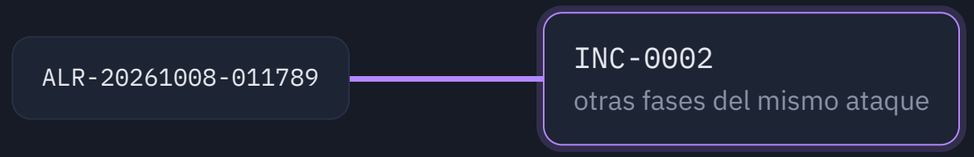


Código recoge datos · **Política** decide por reglas · **IA** razona y propone · **Persona** aprueba

Correlación

Política

Une la alerta con las demás fases del mismo ataque, aunque pasen días.



Así tría una alerta

Cambio de IBAN a Lituania
Fraude BEC tras AiTM

69,9 s acumulado



Código recoge datos · **Política** decide por reglas · **IA** razona y propone · **Persona** aprueba

Persona

● **Persona**

La contención solo se ejecuta si una persona la aprueba. La IA no tiene acceso.

Necesita aprobación humana

`revoke_sessions` laura.ferrer2@tarvia.example **N2**

`reset_password` laura.ferrer2@tarvia.example **N2**

El N1 puede hacerlo ya

`escalate` Tesorería / Finanzas y N2

`block_ioc` 203.0.113.45

`purge_email` <CAF8x9-bec-0...rvia.example>

Aprueba en el dashboard · `POST /approvals` · `approval_token` · `POST /containment`

Escalado a N2.

Medido sobre los datos

90 %
de las alertas las decide la política sola, con justificación

0
ataques cerrados como benignos (de 83 alertas de ataque)

12/12
incidentes reales encontrados, con todas sus alertas

10/10
alertas de incidentes reales marcadas como ataque y escaladas

6/6
inyecciones de prompt detectadas, ninguna obedecida

73 s
para 10 alertas en directo, frente a ~15 min por alerta a mano

1 Triaje básico **hecho** 2 Con criterio **hecho** 3 Investigación **hecho** 4 Respuesta **hecho**

Limitaciones

- Necesita decisión humana: la contención y lo escalado siempre los aprueba una persona; el sistema propone, no actúa solo.
- Sin IA, 49 de 83 alertas de ataque quedan pendientes: nunca se cierran en silencio, pero necesitan IA o persona.

Demo en directo